

MVP de Ciência de Dados e Analytics

**Estrutura Integrada de Dados com Características de ERP e
Arquitetura Medalhão em Databricks**



**Pós-Graduação em Ciência de Dados e Analytics
PUC-Rio**

**Guido Maculan
2026**

Sumário

1. Contexto de Negócio.....	3
1.1 Objetivo.....	3
1.2 Estrutura organizacional.....	3
1.3 Perguntas de negócio e evolução do escopo.....	4
1.4 Princípio central do MVP.....	7
2. Dados e Fontes.....	7
2.1 Anonimização dos dados.....	7
2.2 Fontes utilizadas no pipeline.....	8
2.3 Condição de uso dos dados	
3. Arquitetura de Dados.....	7
4. Conceitos de Negócio e Premissas.....	8
5. Pipeline de Dados.....	9
5.1 Carga dos dados no Databricks	
5.2 Bronze → Silver	
5.3 Silver → Gold	
6. Estado Final da Camada Silver.....	9
7. Modelagem Gold e Catálogo de Tabelas.....	10
8. Qualidade de Dados.....	10
9. Limitações dos Dados e Decisões de Escopo.....	11
10. Premissas e Simplificações de Modelagem.....	12
11. Análises de Negócio.....	13
11.4 Discussão geral dos resultados	
12. Organização dos Notebooks.....	14
12.6 Repositório público e código	
13. Unity Catalog.....	15
14. Autoavaliação.....	20
14.1 Atingimento dos objetivos	
14.2 Experiência técnica e uso de Inteligência Artificial	
14.3 Principais dificuldades	
14.4 Trabalhos futuros	
15. Conclusão.....	20
16. Dicionário de Dados e Modelos Conceitual e Lógico.....	30

1. Contexto de Negócio

O projeto propõe uma estrutura integrada de dados, com características de um ERP, voltada a consultas analíticas sobre Recursos Humanos, Finanças, Faturamento/Clientes e gestão Gerencial/Operacional. A proposta não é reproduzir integralmente um ERP comercial, mas demonstrar como dados distribuídos em controles distintos podem ser integrados em uma arquitetura analítica para responder perguntas de gestão.

Os dados têm como referência controles de uma empresa de Tecnologia da Informação de pequeno a médio porte do Rio de Janeiro. A organização possui estrutura administrativa e departamentos técnicos responsáveis por clientes, projetos, serviços e profissionais. Para fins de anonimização e documentação do MVP, o domínio administrativo foi representado como Nexa.

O conjunto de fontes é parcial. Nem todas as informações históricas e operacionais estavam disponíveis, e parte dos controles migrou posteriormente para outros sistemas aos quais não se obteve acesso. O MVP, portanto, prioriza a demonstração da arquitetura, da qualidade, das relações entre entidades e das consultas que podem ser sustentadas pelos dados efetivamente disponíveis. Ausência de cobertura não é tratada como valor zero e não são criados dados para preencher lacunas históricas.

1.1 Objetivo

Construir um pipeline de dados em nuvem, organizado segundo a arquitetura Medalhão, capaz de integrar informações de empregados, salários, benefícios, férias, dependentes, alocações, faturamento, fornecedores, PJs e tabelas auxiliares, preparando dados confiáveis para consultas analíticas, indicadores e exploração OLAP.

1.2 Estrutura organizacional

A empresa utilizada como referência para o MVP possui uma estrutura organizada em quatro núcleos subordinados à Diretoria. O núcleo NEXA concentra as funções administrativas e de suporte necessárias ao funcionamento da organização e ao atendimento dos núcleos técnicos. Os núcleos NEX0, NEX1 e NEX3 concentram as atividades técnicas relacionadas ao desenvolvimento e à execução dos projetos e serviços prestados aos clientes. Todos os núcleos possuem um gerente responsável. No NEXA estão concentradas áreas como Recursos Humanos, Secretaria de Operações, Financeiro, Contabilidade, Recrutamento e Seleção e Suporte e Infraestrutura. Nos núcleos técnicos atuam, entre outros perfis, gerentes de projeto, analistas de sistemas, desenvolvedores e testadores.




Figura 1 — Estrutura organizacional simplificada da empresa.

1.3 Perguntas de negócio e evolução do escopo

As perguntas abaixo correspondem ao escopo originalmente proposto para o MVP. A situação de cada questão indica se ela foi efetivamente respondida e em qual módulo a análise final foi realizada. As alterações de escopo são explicadas ao final de cada módulo. Essa apresentação preserva a rastreabilidade entre a proposta inicial e o trabalho efetivamente executado.

1.3.1 Módulo Financeiro

Pergunta originalmente proposta	Situação
1. Qual o custo de um funcionário? • Qual seu salário atual? • Qual seu histórico de salários? • Quanto é gasto em benefícios com esse funcionário? • Qual seu histórico de gastos com benefícios? • Qual seu custo total, considerando salário, benefícios, dependentes e encargos calculados?	Respondida — Módulo Recursos Humanos
2. Qual o custo de um grupo de funcionários, por período?	Respondida — Módulo Recursos Humanos
3. Como o custo médio por funcionário evoluiu ao longo do tempo?	Respondida — Módulo Recursos Humanos
4. Qual o custo dos funcionários por função/perfil profissional?	Não respondida

5. Qual o custo de um fornecedor por período?	Respondida
6. Quais fornecedores representam os maiores custos para a empresa?	Respondida
7. Qual o fluxo financeiro em determinado período? • Entradas previstas por faturamento. • Saídas previstas por cobranças. • Saldo previsto.	Respondida

Observação do módulo. As questões 1, 2 e 3, originalmente propostas no Financeiro, foram tratadas no módulo de Recursos Humanos porque dizem respeito à composição e à evolução dos custos dos empregados; mantê-las também no Financeiro produziria duplicidade analítica. A questão 4, custo por função/perfil profissional, não foi respondida. As questões 5, 6 e 7 permaneceram no módulo Financeiro e foram respondidas. O fluxo financeiro foi construído com caráter demonstrativo, segundo as premissas explicitadas posteriormente neste documento.

1.3.2 Módulo Recursos Humanos

Pergunta originalmente proposta	Situação
1. Quando um funcionário sairá de férias?	Respondida
2. Qual o histórico de férias de um funcionário?	Respondida
3. Quantos funcionários estarão de férias em determinado período?	Respondida
4. Qual é a folha de pagamento em determinado período?	Respondida
5. Qual é o índice de turnover da empresa por ano?	Respondida
6. Como o turnover evoluiu ao longo dos anos?	Respondida
7. Quais são os principais motivos de desligamento?	Respondida
8. Existe concentração de desligamentos por cliente/alocação ou função profissional?	Respondida
9. Qual é o tempo médio de casa dos funcionários ativos?	Respondida
10. Qual era o tempo médio de casa dos funcionários no momento do desligamento?	Respondida
11. Existe relação entre tempo de casa e motivo do desligamento?	Respondida
12. Qual é a distribuição do perfil dos dependentes?	Respondida
13. Qual é o impacto dos dependentes no custo dos planos de saúde/dental?	Respondida

Observação do módulo. As 13 perguntas originalmente propostas para Recursos Humanos foram analisadas no notebook final do módulo. A primeira questão de férias foi efetivamente executada: a conclusão registra que não havia períodos futuros de férias já marcados na base e explica por que os registros históricos disponíveis não permitem determinar uma próxima data. A questão sobre concentração de desligamentos utiliza as informações disponíveis de alocação apenas dentro do recorte sustentado pela fonte, sem transformar a alocação parcial em histórico completo.

1.3.3 Módulo Faturamento e Clientes

Pergunta originalmente proposta	Situação
1. Qual o faturamento total por mês e por ano?	Respondida
2. Qual o faturamento por cliente?	Respondida
3. Qual o faturamento por alocação?	Não respondida
4. Como o faturamento evoluiu ao longo do tempo?	Respondida
5. Qual a previsão de faturamento com base no histórico disponível?	Não respondida
6. Qual é a concentração de faturamento nos cinco maiores clientes?	Respondida

7. Como a participação dos maiores clientes no faturamento total evoluiu ao longo do tempo?	Respondida
8. Quais clientes aumentaram ou reduziram sua participação no faturamento?	Respondida
9. Qual o ticket médio das notas fiscais emitidas por mês?	Respondida
10. Qual o ticket médio das notas fiscais por cliente?	Respondida

Observação do módulo. Oito das dez perguntas originalmente propostas foram respondidas. A questão de faturamento por alocação não foi executada porque a fonte de Alocação não possui histórico completo das movimentações necessário para relacionar faturamento e alocação por período. A previsão de faturamento também foi retirada: a série histórica permite análise descritiva, mas não contém variáveis explicativas suficientes para uma projeção considerada defensável. As justificativas completas constam na seção de Limitações dos Dados e Decisões de Escopo.

1.3.4 Módulo Gerencial — Alocações e Rentabilidade

Pergunta originalmente proposta	Situação
1. Qual o custo total de cada alocação?	Não respondida
2. Qual o custo de pessoal de cada alocação?	Não respondida
3. Qual o valor das cobranças rateadas para cada alocação?	Não respondida
4. Qual o faturamento de cada alocação?	Não respondida
5. Qual a margem gerencial de cada alocação?	Não respondida
6. Como a margem das alocações evolui ao longo do tempo?	Não respondida
7. Quais alocações apresentam as maiores e menores margens?	Não respondida
8. Quais alocações apresentam deterioração da margem ao longo do tempo?	Não respondida
9. Qual a composição do custo de cada alocação? • salários; benefícios; encargos; dependentes; cobranças rateadas.	Não respondida
10. Qual a relação entre faturamento e custo de pessoal por alocação?	Não respondida
11. Qual a receita por funcionário alocado?	Não respondida
12. Quais clientes/alocações concentram os profissionais de maior custo?	Não respondida
13. Como alterações salariais impactaram o custo e a margem das alocações ao longo do tempo?	Não respondida

Observação do módulo. As 13 perguntas originalmente propostas para Alocações e Rentabilidade não foram executadas. A base disponível não contém histórico completo das movimentações de alocação, apontamento de horas (timesheets) nem base temporal suficiente para associar, de forma consistente, empregados, custos e faturamento à mesma alocação. Produzir custos, receitas ou margens por alocação exigiria premissas adicionais não sustentadas pelas fontes. A decisão foi, portanto, não gerar associações artificiais para responder a essas questões.

1.4 Princípio central do MVP

O foco é demonstrar uma arquitetura integrada e reproduzível, preservando a diferença entre dado observado, premissa de modelagem e cálculo derivado. Quando uma fonte não oferece cobertura suficiente para determinada visão, a limitação é documentada em vez de ser compensada por inferências não sustentadas.

2. Dados e Fontes

As fontes originais eram planilhas e controles operacionais. Os arquivos utilizados no pipeline foram anonimizados antes da carga no Databricks. A anonimização está encerrada e não faz parte da transformação Bronze → Silver.

2.1 Anonimização dos dados

A utilização de dados provenientes de controles reais exigiu uma etapa prévia de anonimização antes da carga no ambiente Databricks. Essa etapa mostrou-se significativamente mais complexa do que a simples substituição de valores identificáveis, pois foi necessário preservar a coerência entre informações relacionadas existentes em diferentes fontes.

A anonimização abrangeu dados de empregados, dependentes, clientes, fornecedores e prestadores de serviço, incluindo nomes, nomes reduzidos, CPF/CNPJ, endereços, documentos pessoais, nomes de familiares, empresas e demais informações capazes de permitir identificação. Também foram anonimizadas informações empresariais e operacionais, como clientes, fornecedores, notas fiscais e componentes dos Centros de Resultado.

Um dos principais desafios foi manter a integridade referencial e a consistência semântica após a anonimização. Uma mesma pessoa, empresa ou entidade presente em fontes diferentes precisava receber a mesma identidade fictícia em todas elas. Da mesma forma, situações de reconstrução precisavam preservar a distinção entre vínculo empregatício e pessoa, permitindo que diferentes DRTs associados à mesma pessoa continuassem reconhecíveis após a anonimização.

Os Centros de Resultado exigiram tratamento específico. Sua estrutura possui significado para o negócio e não poderia ser substituída indiscriminadamente sem comprometer as relações posteriormente utilizadas nas análises. A anonimização precisou, portanto, alterar os componentes identificáveis preservando a estrutura necessária para representar núcleos, clientes, projetos e sequências.

A etapa foi realizada antes da persistência dos dados utilizados pelo pipeline analítico. Dessa forma, a camada Bronze já constitui o ponto inicial anonimizado do MVP; os dados reais identificáveis não são mantidos nas camadas Bronze, Silver ou Gold. A transformação Bronze → Silver, portanto, não corresponde a uma nova etapa de anonimização, mas ao tratamento, seleção, tipagem, padronização e validação dos dados já protegidos.

A complexidade dessa etapa também decorreu da necessidade de validar os resultados após cada transformação. Não era suficiente verificar se os valores originais haviam sido substituídos: era necessário confirmar que quantidades de registros, relacionamentos, chaves de negócio e correspondências entre tabelas permanecessem coerentes. Esse processo exigiu sucessivas inspeções e validações antes que as fontes anonimizadas fossem consideradas adequadas para a carga definitiva na Bronze.

A anonimização deve, portanto, ser entendida como uma etapa preparatória relevante do projeto, necessária para conciliar a proteção das informações originais com a preservação da utilidade analítica e das relações existentes entre os dados. Embora não faça parte das transformações da arquitetura Medalhão propriamente dita, constituiu uma das etapas de preparação de dados mais trabalhosas do MVP.

2.2 Fontes utilizadas no pipeline

As fontes utilizadas no MVP foram obtidas a partir de planilhas e controles operacionais com diferentes finalidades, granularidades e períodos de cobertura. Após a etapa de anonimização, os dados foram carregados na camada Bronze, que constitui o ponto inicial persistido da arquitetura Medalhão. A tabela a seguir apresenta a finalidade de cada fonte no projeto e as principais características que condicionam seu uso analítico. A descrição detalhada dos campos, tipos de dados e domínios permanece concentrada no Dicionário de Dados.

Fonte	Conteúdo e utilização no MVP	Características / limitações relevantes
Empregados	Cadastro dos empregados e respectivos vínculos empregatícios. É a principal referência para os DRTs e fornece informações cadastrais, admissão, desligamento e características dos vínculos.	O DRT identifica o vínculo, e não necessariamente a pessoa. Recontrações podem gerar DRTs diferentes para a mesma pessoa.
Salários	Histórico salarial dos empregados, utilizado na reconstrução da evolução dos salários e nos cálculos de custo de pessoal.	A cobertura histórica deve ser interpretada em conjunto com os períodos dos respectivos vínculos.
Benefícios	Informações de benefícios dos titulares, utilizadas no tratamento de TR, TA e plano de saúde.	A fonte principal possui pouco histórico e não constitui uma série temporal completa dos valores. Tabelas auxiliares foram utilizadas para a reconstrução histórica dos custos.
Dependentes	Cadastro dos dependentes associados aos empregados, utilizado nas análises de perfil e na composição dos custos de saúde dos dependentes.	Não há histórico completo das datas de inclusão e exclusão dos dependentes nos planos, limitando a reconstrução temporal exata desses custos.
Férias	Histórico de direitos e períodos de gozo de férias, utilizado nas análises de férias e na composição de custos de pessoal e do fluxo financeiro demonstrativo.	Origem em planilha mantida manualmente. A sequência da fonte não foi considerada chave de negócio confiável; foram necessários tratamentos de duplicidades e de inconsistências identificadas.
Alocação	Informações sobre alocação principal, atividade e data de início dos empregados, utilizadas para representar a estrutura de alocação disponível.	Fonte parcial, sem histórico completo das movimentações e sem apontamento de horas. Não permite apropriar historicamente custos, faturamento ou margens às alocações.
Faturamento	Registros de notas fiscais, clientes, Centros de Resultado, competências, datas e valores utilizados nas análises de receita.	Uma mesma combinação de Centro de Resultado e competência pode possuir mais de uma NF. Na Gold, o tratamento foi orientado para obter uma linha por NF real.
Fornecedores	Registros de fornecedores, competências e valores utilizados nas análises de despesas com fornecedores e no fluxo financeiro demonstrativo.	Base compilada especificamente para o MVP a partir de amostras de fluxos financeiros; não representa o histórico completo das despesas da empresa.
PJ	Cadastro de prestadores de serviço pessoa jurídica.	Possui natureza cadastral e não contém medidas financeiras ou temporais suficientes para constituir uma tabela fato. Não foi encontrada correspondência sustentada com a amostra de fornecedores.
Plano de saúde até 2022	Tabela auxiliar com referências históricas de valores de plano de saúde, utilizada na reconstrução dos custos de assistência à saúde.	Sua cobertura temporal deve ser respeitada; ausência de valor fora da cobertura não é interpretada automaticamente como custo zero.
Plano de saúde a partir de 2022	Tabela auxiliar que dá continuidade à reconstrução dos custos de plano de saúde no período posterior.	Complementa a fonte anterior e deve ser interpretada segundo seu período efetivo de cobertura.
Valores de ticket 2010–2025	Tabela auxiliar com valores históricos utilizados na reconstrução dos custos de TR e TA.	Os valores são utilizados segundo as premissas de cálculo documentadas no MVP; períodos sem cobertura não são automaticamente tratados como custo zero.

No Databricks, essas fontes são persistidas na Bronze em tabelas anonimizadas e tabelas auxiliares. A nomenclatura física dos objetos, sua organização por camada e a finalidade de cada tabela são apresentadas na seção 13 — Unity Catalog, evitando duplicar no capítulo de fontes a listagem técnica do catálogo.

2.3 Condição de uso dos dados

Os dados utilizados têm origem em controles empresariais disponibilizados para finalidade acadêmica e não constituem uma base pública submetida a licença aberta de distribuição. Por essa razão, os arquivos de dados não integram a entrega pública do projeto. Antes da carga em ambiente externo, as informações identificáveis de pessoas e empresas foram anonimizadas, preservando-se apenas as relações necessárias ao desenvolvimento analítico. O repositório público do MVP disponibiliza o código, a documentação e as evidências do pipeline, mas não os dados empresariais de origem.

3. Arquitetura de Dados

Camada	Papel no projeto
Origem	Planilhas e controles operacionais disponíveis.
Preparação/anonimização	Etapa temporária já encerrada, destinada à proteção das informações identificáveis.
Bronze	Dados já anonimizados, em granularidade próxima da origem, preservados para rastreabilidade.
Silver	Dados selecionados, tratados, tipados, padronizados, limpos e validados.
Gold	Dimensões, fatos e estruturas consolidadas para consultas analíticas, indicadores e exploração OLAP.

A transformação Bronze → Silver não constitui nova anonimização. Cada tratamento é documentado e validado. A Gold foi modelada a partir das perguntas de negócio e das limitações efetivas das fontes.

4. Conceitos de Negócio e Premissas

4.1 DRT, pessoa e vínculo

DRT funciona como a matrícula do empregado na empresa e identifica um vínculo empregatício específico. Por esse motivo, ele não identifica necessariamente uma pessoa de forma única: em caso de recontratação, a mesma pessoa pode receber um novo DRT, passando a possuir diferentes matrículas correspondentes a vínculos distintos. O CPF anonimizado é utilizado para reconhecer a mesma pessoa entre esses diferentes vínculos. Na base final de Empregados existem 347 vínculos válidos.

A data de desligamento e o motivo de desligamento caracterizam o vínculo. Após a revisão final da Silver, 333 vínculos possuem data e motivo de desligamento e 14 vínculos permanecem ativos, com ambos os campos nulos.

4.2 Alocação

A fonte de Alocação é parcial e não possui cobertura temporal compatível com todas as demais fontes. Não há histórico completo das movimentações dos empregados nem apontamento de horas que permita reconstruir, por período, a associação efetiva entre empregado, projeto, cliente ou centro de resultado.

Não é adotado relacionamento estrutural que force custos de empregados ou faturamento histórico à Dim_Alocacao como se houvesse cobertura integral. A dimensão foi preservada para representar as informações efetivamente disponíveis, mas não foi utilizada para apropriação histórica de custos, receitas ou margens. Usos pontuais da informação de alocação somente são apresentados quando compatíveis com o recorte observado e com a limitação explicitada.

4.3 Faturamento

Os dados demonstraram que uma mesma combinação de Centro de Resultado pode possuir mais de uma NF na mesma competência. Na Gold, divisões artificiais da mesma NF foram consolidadas para obter uma linha por NF real. Cancelamentos foram excluídos e CR4 nulo pode ser legítimo.

4.4 Fornecedores e PJ

Fornecedores constituem uma amostra. A Silver preserva os registros observados e qualquer cálculo derivado deve permanecer distinguível da fonte.

A fonte de PJ contém informações cadastrais dos prestadores de serviço pessoa jurídica, mas não apresenta um histórico de valores, pagamentos ou outros eventos associados a esses prestadores. Por esse motivo, os dados foram mantidos como informação cadastral e não foi criada uma tabela fato específica para PJ. Não foi encontrada correspondência entre os 10 PJs distintos e a amostra de fornecedores. Portanto, não foi criada Fato_PJ e os PJs não foram incorporados à Fato_Fornecedor.

4.5 Benefícios, saúde e dependentes

Benefícios do titular e custos de dependentes são tratados separadamente. A fonte principal de benefícios possui pouco histórico e não representa uma série temporal completa. As datas de admissão e desligamento são utilizadas para limitar os meses ativos nos cálculos de custo. Para dependentes, a ausência de datas de inclusão/exclusão do plano exige premissas explicitadas no fato correspondente.

4.6 Férias

A fonte de férias é uma planilha mantida manualmente. A sequência não é tratada como chave de negócio confiável. Duplicidades de DRT + período aquisitivo são resolvidas mantendo a menor sequência. Um erro confirmado no período aquisitivo do DRT325 é corrigido somente na Gold, preservando Bronze e Silver.

5. Pipeline de Dados

O pipeline foi executado em Databricks segundo a arquitetura Medalhão. A metodologia de desenvolvimento adotou ciclos curtos e verificáveis: documentar a regra, executar uma transformação por vez, avaliar o resultado e somente então avançar.

5.1 Carga dos dados no Databricks

Após a preparação e a anonimização, as planilhas finais foram carregadas no Databricks e persistidas no catálogo `workspace`, schema `bronze`. Essa carga estabelece o ponto inicial do pipeline em nuvem: a Bronze recebe somente dados já protegidos e tabelas auxiliares necessárias às transformações posteriores. A partir dessas tabelas persistidas, os notebooks executam as transformações Bronze → Silver e Silver → Gold de forma reproduzível. A organização dos notebooks responsáveis pela carga e pelas transformações é detalhada na seção 12, e a persistência física das tabelas é evidenciada no Unity Catalog apresentado na seção 13.

5.2 Bronze → Silver

A Silver aplica seleção de atributos, tipagem, padronização, tratamento consciente de nulos, remoção de duplicidades quando aplicável e correções sustentadas por evidência da fonte. As tabelas Silver foram construídas e validadas.

5.3 Silver → Gold

A Gold organiza os dados em dimensões e fatos orientados às perguntas analíticas. As dimensões e fatos previstos no escopo final foram construídos, persistidos e validados, constituindo a camada de consumo utilizada nas análises de Recursos Humanos, Financeiro e Faturamento.

6. Estado Final da Camada Silver

Domínio	Estado	Resultado principal
Empregados	Fechada/revalidada	347 DRTs; 15 atributos; 333 desligados com data e motivo; 14 ativos; motivo `135` tratado como nulo; data de desligamento proveniente de `DESLIGAMENTO11`.
Salários	Fechada	1.512 registros históricos; 347 DRTs; salário tipado; campo cargo disponível, com 2 nulos.
Benefícios	Fechada	342 DRTs; snapshot do titular; TR, TA, plano de saúde e total de benefícios.
Dependentes	Fechada	218 dependentes; 130 DRTs; sem duplicidade DRT + nome.
Férias	Fechada	882 registros válidos; 346 DRTs; períodos aquisitivos e até três períodos de gozo.
Faturamento	Fechada	Silver preparada para modelagem financeira; múltiplas NFs por CR/competência são permitidas.
Fornecedores	Fechada	850 registros; 141 fornecedores; 37 competências; fonte amostral.
PJ	Fechada	10 registros cadastrais distintos; sem medida financeira/temporal.
Alocação	Fechada	342 registros no escopo; fonte parcial; sem extrapolação.

7. Modelagem Gold e Catálogo de Tabelas

7.1 Dimensões

Tabela	Grão / conteúdo	Validação principal
workspace.gold.dim_entidade	Entidade cliente/fornecedor	176 entidades: 35 de receita e 141 de despesa; CANCELAMENTO excluído.
workspace.gold.dim_empregado	Um registro por vínculo (DRT)	347 registros/IDs/DRTs; motivo de desligamento; FKs temporais de admissão/desligamento; 14 vínculos ativos.
workspace.gold.dim_alocacao	Uma linha por alocação principal/atividade	61 registros; mantida sem forçar integração histórica com custos/faturamento.
workspace.gold.dim_tempo	Um registro por dia	Calendário contínuo com 34.086 linhas; atende às datas utilizadas pelos fatos e pela Dim_Empregado.
workspace.gold.dim_saude	Referências para custos de plano de saúde	Usada nos cálculos históricos de saúde.

7.2 Fatos

Tabela	Grão	Resultado principal
workspace.gold.fato_custo_pessoal	DRT × ano	1.147 registros; 341 DRTs; 2000–2024; salário, benefícios do titular, férias, 13º, FGTS, encargos e custo total do empregado.
workspace.gold.fato_dependentes	Dependente × DRT × ano	712 registros; 218 dependentes; 130

		DRTs; 2010–2026.
workspace.gold.fato_ferias	Direitos/gozos de férias por vínculo e período	995 registros; 340 DRTs; 873 direitos; 679 gozos; 316 registros sem gozo.
workspace.gold.fato_faturamento	Uma linha por NF real	3.907 registros e 3.907 NFs; 0 duplicidades/cancelamentos; cobertura 11/2011 a 20/10/2025.
workspace.gold.fato_fornecedor	Fornecedor × competência observada	848 registros; 141 fornecedores; 37 competências; 04/2015–12/2025.

Não foi criada Fato_PJ, pois a fonte PJ é apenas cadastral e não contém medidas financeiras ou temporais suficientes.

8. Qualidade de Dados

A avaliação de qualidade foi realizada considerando as dimensões de completude, consistência, unicidade, acurácia e identificação de valores extremos ou anômalos. Como as fontes possuem naturezas e granularidades distintas, esses critérios foram aplicados segundo as regras de negócio de cada domínio, sem interpretar automaticamente ausência de cobertura como erro ou valor zero.

- Completude: foram verificados valores nulos e ausências relevantes, distinguindo lacunas efetivas de períodos ou atributos que não possuem cobertura na fonte. Exemplos incluem os nulos de endereço em Empregados e os períodos anteriores à cobertura das tabelas auxiliares.
- Consistência: foram verificadas compatibilidades entre campos, regras de negócio e relações entre camadas, incluindo situação do vínculo, motivo de desligamento, correspondência temporal e coerência entre Silver e Gold.
- Unicidade: foram verificadas chaves e grãos esperados, com tratamento de duplicidades quando incompatíveis com a regra de negócio, como em Férias, Fornecedores e na consolidação do Faturamento por nota fiscal real.
- Acurácia: valores ou registros incompatíveis com a semântica conhecida da fonte foram investigados e somente corrigidos quando havia evidência objetiva, como o valor anômalo `135` e o erro confirmado no período aquisitivo do DRT325.
- Outliers e anomalias: valores extremos ou incomuns foram tratados como sinais para inspeção, e não removidos automaticamente. A decisão de manter, corrigir ou excluir um registro dependeu da regra de negócio e da evidência disponível.
- Empregados: 347 vínculos válidos e DRTs únicos; 14 vínculos ativos; 333 desligados com motivo; 0 desligados sem motivo; 0 ativos com motivo.
- O valor anômalo `135` em data/motivo de desligamento foi tratado como nulo por regra de qualidade confirmada.
- Dim_Empregado: 0 admissões e 0 desligamentos sem correspondência com Dim_Tempo; 0 divergências de motivo entre Silver e Gold.
- Endereço de empregados preserva ausências da fonte: 1 nulo em logradouro, bairro, cidade e estado; 3 em CEP.
- Férias: duplicidades e erro confirmado do DRT325 tratados segundo regras documentadas.
- Faturamento: Gold com uma linha por NF real, sem duplicidades e sem cancelamentos.
- Fornecedores: duas duplicidades fornecedor+competência consolidadas na Gold; fonte permanece explicitamente amostral.
- Nulos anteriores à cobertura histórica de ticket/plano de saúde não são interpretados automaticamente como custo zero.

9. Limitações dos Dados e Decisões de Escopo

O MVP foi desenvolvido a partir de dados históricos provenientes de planilhas e controles operacionais disponibilizados para o projeto. As fontes possuem diferentes períodos de cobertura, granularidades e níveis de completude. Por esse motivo, as análises foram limitadas às relações que puderam ser sustentadas pelos dados disponíveis. A ausência de

informação não foi interpretada automaticamente como valor zero nem preenchida por inferência sem evidência objetiva.

9.1 Cobertura temporal das fontes

As fontes de empregados, salários, benefícios, férias, dependentes, alocação, faturamento, fornecedores e tabelas auxiliares não apresentam necessariamente a mesma cobertura temporal. Comparações integradas devem, portanto, utilizar períodos compatíveis ou declarar explicitamente as diferenças. Valores nulos anteriores ao início da cobertura histórica das tabelas auxiliares de ticket e plano de saúde não são interpretados automaticamente como custo zero.

9.2 Alocação e módulo Gerencial/Alocações e Rentabilidade

A base de Alocação contém informações sobre a alocação principal dos empregados, atividade e data de início, mas não dispõe de histórico completo das movimentações ao longo do tempo. Também não estão disponíveis apontamentos de horas (timesheets) ou outra informação que permita determinar, para cada período, quanto do trabalho de cada empregado esteve efetivamente associado a determinado projeto, cliente ou centro de resultado. Essa limitação impede estabelecer, com consistência temporal, a relação entre empregado, alocação, custo de pessoal e faturamento.

Consequentemente, as 13 perguntas inicialmente propostas para o módulo Gerencial/Alocações e Rentabilidade não foram executadas analiticamente. Cálculos de custo, faturamento, margem, composição de custos e receita por empregado alocado exigiriam associações adicionais não sustentadas pelas fontes. A tabela de Alocação foi tratada e incorporada ao modelo para representar as informações efetivamente disponíveis, mas não foi utilizada como se constituísse um histórico completo. Essa restrição não impede usos pontuais da informação disponível, como a investigação de concentração de desligamentos realizada no módulo de RH, desde que a limitação do recorte seja respeitada.

9.3 Faturamento por alocação

A pergunta “Qual o faturamento por alocação?”, inicialmente prevista no módulo de Faturamento, foi retirada do escopo pela mesma limitação temporal. A existência separada de informações de faturamento e alocação não é suficiente para associá-las historicamente de forma consistente. Optou-se por não produzir associações artificiais para responder à questão.

9.4 Previsão de faturamento

A previsão de faturamento inicialmente considerada também foi retirada do escopo final. O histórico disponível permite analisar a evolução temporal da receita, mas não contém variáveis explicativas suficientes para representar contratos, entrada e saída de clientes, novos projetos, renegociações e outras condições capazes de influenciar o faturamento futuro. Por isso, não foi apresentada uma extrapolação baseada exclusivamente na série histórica como previsão de receita.

9.5 Fornecedores

A base de fornecedores foi compilada especificamente para o MVP a partir de amostras de fluxos financeiros e não representa o histórico completo das despesas da empresa. Os resultados de custos e concentração de fornecedores representam exclusivamente os registros disponíveis e não devem ser generalizados como a totalidade histórica das despesas.

9.6 Prestadores de serviço — PJ

A fonte de PJ possui natureza cadastral e não contém medidas financeiras ou temporais suficientes para a construção de uma tabela fato. Também não foi encontrada correspondência que permitisse integrar de forma sustentada os 10

PJs distintos à amostra de fornecedores. Por esse motivo, não foi criada Fato_PJ e os registros de PJ não foram artificialmente incorporados à Fato_Fornecedor.

9.7 Benefícios, plano de saúde e dependentes

A fonte principal de benefícios não constitui uma série operacional histórica completa. Para as análises históricas foram utilizadas as tabelas auxiliares disponíveis de valores de ticket e planos de saúde, juntamente com as datas de admissão e desligamento. A fonte de dependentes também não contém histórico completo das datas de inclusão e exclusão nos planos. Assim, os custos históricos correspondentes devem ser interpretados segundo as regras e premissas documentadas no modelo.

9.8 Férias

A fonte de férias é uma planilha histórica mantida manualmente e não contém necessariamente atualizações posteriores aos registros disponíveis. Na análise sobre as próximas férias, não foram encontrados períodos futuros já marcados. Os 316 registros identificados correspondem a direitos ainda sem programação na base, abrangendo 312 vínculos. Esse resultado não permite concluir que os empregados estejam com férias em atraso, pois não existem informações posteriores suficientes para verificar eventual marcação ou gozo. A consulta foi executada e sua conclusão explícita precisamente essa limitação da fonte.

9.9 Limites de interpretação

Os indicadores produzidos têm finalidade analítica e demonstrativa. Turnover, motivos de desligamento, permanência, concentração de receita ou concentração de despesas identificam padrões presentes nos dados, mas não estabelecem, isoladamente, relações causais. Os resultados também não devem ser extrapolados para períodos, processos ou populações não representados pelas respectivas fontes.

10. Premissas e Simplificações de Modelagem

Para viabilizar a integração das fontes e a construção das estruturas analíticas, algumas regras foram estabelecidas especificamente para o MVP. Essas regras constituem premissas e simplificações de modelagem e não devem ser interpretadas como reprodução integral dos processos operacionais, financeiros, trabalhistas ou contábeis da empresa utilizada como referência. Em determinados casos, a regra adotada simplifica deliberadamente uma prática real; seu objetivo é permitir a demonstração do pipeline, da integração dos dados e das análises dentro do escopo acadêmico do projeto.

10.1 Ticket refeição e ticket alimentação

Para os cálculos do MVP, os valores mensais de TR e TA foram convertidos em valores diários pela divisão por 21 dias úteis e ajustados aos dias úteis do vínculo no mês. Foram considerados dias de segunda a sexta-feira, sem exclusão de feriados, pois os feriados não foram modelados para esse cálculo. No fluxo financeiro demonstrativo, TR e TA foram posicionados juntamente com o salário no 5º dia útil do mês subsequente à competência. Essa convenção é uma simplificação do modelo e não representa necessariamente o momento real de concessão desses benefícios, que pode ocorrer antecipadamente em relação ao período de utilização.

10.2 Férias

No fluxo financeiro demonstrativo, o pagamento de férias foi posicionado dois dias antes do início do período de gozo e calculado como salário acrescido de um terço. Como simplificação do MVP, foi considerado o valor integral mesmo quando o gozo estivesse fracionado.

10.3 Décimo terceiro salário e FGTS

Para o fluxo financeiro demonstrativo, o décimo terceiro foi representado em duas parcelas de 50%, posicionadas em 30/11 e 20/12, com FGTS de 8% considerado em cada parcela. Na folha analítica mensal, o FGTS foi calculado sobre o salário do período e o avo de décimo terceiro adquirido no mês, evitando contabilizar novamente provisões acumuladas de meses anteriores. Essas regras correspondem à implementação adotada no MVP.

10.4 Plano de saúde

Os custos históricos de plano de saúde foram reconstruídos a partir das tabelas auxiliares disponíveis e dos períodos ativos dos vínculos. No fluxo demonstrativo, os valores de saúde de titulares e dependentes foram posicionados no dia 24 da respectiva competência. Essa data constitui uma convenção de modelagem utilizada no MVP.

10.5 Fornecedores e vencimentos

A fonte amostral de fornecedores não possui, para todo o escopo necessário ao fluxo, uma data transacional de vencimento que permita reproduzir o calendário real de pagamentos. Para viabilizar a demonstração, foi utilizada uma regra sintética de vencimento por faixa de valor. Essa regra é uma premissa do modelo e não deve ser interpretada como condição contratual real dos fornecedores.

10.6 Fluxo financeiro demonstrativo

O fluxo financeiro construído no MVP é uma representação analítica demonstrativa, e não a reprodução do fluxo de caixa realizado da empresa. As datas de determinados pagamentos foram definidas por regras de modelagem quando não havia datas transacionais suficientes nas fontes. O saldo calculado parte de saldo inicial igual a zero e considera exclusivamente os movimentos representáveis a partir das fontes e premissas do projeto; portanto, não corresponde ao saldo bancário histórico da empresa.

11. Análises de Negócio

As análises suportadas pelos dados foram concluídas nos módulos de Recursos Humanos, Financeiro e Faturamento. O escopo final corresponde às 24 questões apresentadas na seção 1.2. As questões retiradas não são tratadas como pendências, mas como decisões de escopo fundamentadas nas limitações descritas na seção 9.

11.1 Recursos Humanos

O módulo contempla férias futuras e histórico de férias, quantidade de empregados em férias por período, folha/custo de pessoal, turnover anual e sua evolução, motivos de desligamento, concentração de desligamentos por cliente/alocação ou função profissional dentro do recorte disponível, tempo médio de casa, relação entre permanência e motivo de saída, perfil dos dependentes e impacto dos dependentes no custo do plano de saúde. A primeira questão de férias foi efetivamente executada; sua conclusão registra que não havia períodos futuros marcados na base e explica por que os dados históricos disponíveis não permitem determinar uma próxima data de férias.




Figura 2 — Evolução do turnover anual no período disponível.




Figura 3 — Principais motivos de desligamento observados na base.




Figura 4 — Composição do custo do plano de saúde entre titulares e dependentes.

11.2 Financeiro

As análises financeiras de custos de pessoal inicialmente previstas foram consolidadas no módulo de Recursos Humanos para evitar duplicidade. O módulo Financeiro final concentra-se em custo de fornecedor por período, concentração dos maiores custos de fornecedores e fluxo financeiro demonstrativo. Para 2024, a análise de fornecedores identificou 34 fornecedores e R\$ 2.163.780,61 na amostra, com participação de 25,57% dos três maiores, 39,22% dos cinco maiores e 67,95% dos dez maiores. O fluxo demonstrativo de 2024 reuniu 1.486 movimentos, R\$ 10.819.635,11 a receber, R\$ 7.070.279,29 a pagar e saldo modelado de R\$ 3.749.355,82, que não deve ser interpretado como saldo bancário.




Figura 5 — Dez maiores custos de fornecedores na amostra de 2024.

11.3 Faturamento

O módulo analisa faturamento mensal e anual, faturamento por cliente, evolução da receita, concentração nos cinco maiores clientes, evolução da participação dos maiores clientes, aumento ou redução de participação e ticket médio por mês e por cliente. A base Gold contém 3.907 notas fiscais reais, com cobertura de novembro de 2011 a 20/10/2025. As questões de faturamento por alocação e previsão foram retiradas pelos motivos descritos nas seções 9.3 e 9.4.




Figura 6 — Evolução do faturamento anual entre 2012 e 2024.




Figura 7 — Faturamento histórico dos cinco maiores clientes.

11.4 Discussão geral dos resultados

Em conjunto, as análises demonstram que a arquitetura construída permite integrar informações de pessoas, custos, fornecedores e faturamento em uma base analítica comum, respeitando os diferentes períodos de cobertura e as limitações de cada fonte. Os módulos de Recursos Humanos, Financeiro e Faturamento produziram respostas para as perguntas sustentadas pelos dados, enquanto as questões que exigiriam associações temporais inexistentes ou variáveis explicativas não disponíveis foram mantidas no objetivo original e explicitamente classificadas como não respondidas.

Os resultados devem ser interpretados como evidências descritivas do conjunto de dados disponível. Indicadores como turnover, concentração de receita, concentração de despesas, permanência e custos de pessoal apoiam a leitura gerencial do histórico observado, mas não estabelecem causalidade nem autorizam extrapolação para períodos ou processos não cobertos. Essa distinção entre dado observado, premissa de modelagem e cálculo derivado orientou tanto as análises realizadas quanto as decisões de não produzir respostas artificiais para Alocação/Rentabilidade e previsão de faturamento.

12. Organização dos Notebooks

Os notebooks foram organizados abaixo de acordo com a etapa do pipeline em que atuam. Essa organização permite identificar com clareza quais notebooks realizam a preparação e carga da Bronze, quais executam os tratamentos da Silver, quais constroem as dimensões e fatos da Gold e quais contêm as análises de negócio. O projeto possui 25 notebooks no Workspace do Databricks. Após a publicação final no GitHub, os respectivos links poderão ser associados a esta relação.

12.1 Preparação e anonimização

A anonimização antecede a arquitetura Medalhão persistida. O notebook desta etapa prepara e anonimiza as fontes antes de sua utilização na camada Bronze.

- **Anonimizacao_dados_bronze** — executa a preparação e a anonimização das fontes utilizadas no MVP, preservando as correspondências necessárias entre pessoas, entidades e demais informações antes da persistência dos dados anonimizados.

A anonimização dos dados constituiu uma das etapas mais trabalhosas do desenvolvimento do MVP. Embora inicialmente parecesse possível tratar cada fonte de forma relativamente independente, verificou-se que a preservação da **consistência entre as diferentes bases** era essencial para que os dados continuassem utilizáveis nas etapas posteriores de integração e análise.

As primeiras tentativas de anonimização foram realizadas de forma individual sobre as diferentes planilhas. Essa abordagem mostrou-se inadequada porque uma mesma pessoa, empresa, cliente ou outra entidade podia aparecer em diversas fontes. Era necessário garantir que uma informação anonimizada em uma base recebesse exatamente a mesma identidade fictícia nas demais. O problema tornou-se particularmente evidente nos casos de **recontratação**, pois uma mesma pessoa podia possuir diferentes DRTs ao longo do tempo. Como o DRT identifica o vínculo empregatício e não necessariamente a pessoa, a anonimização precisava reconhecer essas ocorrências como pertencentes ao mesmo indivíduo, utilizando o CPF como elemento de associação.

Também foram encontradas dificuldades na anonimização dos **Centros de Resultado (CRs)**. Esses códigos possuem estrutura hierárquica e aparecem em diferentes fontes, especialmente Alocação e Faturamento. A substituição não poderia ser simplesmente textual: era necessário preservar a coerência entre núcleo, cliente, projeto e demais componentes do código, mantendo simultaneamente a correspondência entre as tabelas.

Na tentativa de tornar o processo reproduzível, foram desenvolvidas rotinas em Python/PySpark e diferentes mapas de correspondência (*DE* → *PARA*) para pessoas, clientes, empresas, PJs, fornecedores e Centros de Resultado. Apesar de conceitualmente mais adequada, essa abordagem gerou sucessivos ciclos de validação e correção. Em algumas execuções, campos que deveriam estar anonimizados ainda apresentavam informações identificáveis; em outras, uma correção realizada em determinada fonte não preservava adequadamente a correspondência com outra. Também ocorreram situações em que fontes já tratadas voltavam a ser processadas, produzindo novas versões e exigindo novas inspeções.

Outro requisito que aumentou a complexidade foi a opção por utilizar **identidades fictícias plausíveis**, em vez de substituições genéricas como EMPREGADO_01, CLIENTE_01 ou FORNECEDOR_01. Essa decisão melhorou a legibilidade e o realismo dos dados utilizados no MVP, mas exigiu controles adicionais para assegurar que as substituições permanecessem consistentes em todas as fontes.

O processo acabou consumindo um tempo significativamente superior ao inicialmente previsto. A cada nova tentativa de automatização eram necessárias novas verificações e, em alguns casos, surgiam problemas que já haviam sido solucionados anteriormente. Considerando o prazo disponível para as demais etapas do MVP — construção das camadas Bronze, Silver e Gold, modelagem, análises e documentação —, o custo do retrabalho passou a superar o benefício de continuar buscando uma automatização integral da anonimização.

Diante disso, optou-se por **interromper a tentativa de automatizar completamente a geração das bases finais**. Os mapas, regras e resultados já obtidos foram aproveitados, mas as correções e substituições finais necessárias foram realizadas manualmente nas planilhas. Essa decisão permitiu realizar uma inspeção direta das informações, preservar as correspondências necessárias entre as fontes e, principalmente, estabelecer uma versão final estável dos dados anonimizados.

Portanto, a execução manual da etapa final não decorreu da ausência de tentativa de automatização. Ao contrário, foi uma **decisão pragmática decorrente da experiência com sucessivos ciclos de automação, validação e retrabalho**. Para o escopo e o prazo do MVP, tornou-se mais eficiente concluir e validar manualmente as bases do que continuar investindo tempo no aperfeiçoamento de uma rotina de anonimização que seria utilizada apenas para preparar o conjunto de dados acadêmico.

Uma vez concluídas e verificadas as planilhas finais, elas foram carregadas no Databricks e passaram a constituir a **camada Bronze utilizada pelo projeto**. A partir desse momento, a anonimização foi considerada encerrada, evitando que as etapas posteriores do pipeline reabrissem transformações já validadas.

12.2 Camada Bronze

Os notebooks da camada Bronze realizam a carga e a preparação das fontes já anonimizadas que constituem o ponto inicial persistido do pipeline. Alguns notebooks agrupam fontes relacionadas na mesma etapa de carga.

- **02_Bronze_Silver_Salario_Beneficio_Anonimizado** — realiza a carga e a preparação das fontes de Salários e Benefícios, incluindo o suporte às estruturas posteriormente tratadas na Silver.
- **03_Bronze_Ferias_Dependentes_Anonimizado** — realiza a carga e a preparação das fontes de Férias e Dependentes.
- **04_Bronze_Faturamento_Anonimizado** — realiza a carga e a preparação da fonte de Faturamento anonimizada.
- **05_Bronze_PJ_Fornecedor_Anonimizado** — realiza a carga e a preparação das fontes anonimizadas de prestadores PJ e Fornecedores.

- **06_Bronze_Alocacao_Anonimizada** — realiza a carga e a preparação da fonte anonimizada de Alocação.

As 12 tabelas físicas que compõem a camada Bronze são:

- **workspace.bronze.alocacao_anonimizado** — recorte anonimizado de alocação principal.
- **workspace.bronze.beneficio_anonimizado** — benefícios do titular disponíveis na fonte de origem.
- **workspace.bronze.dependentes_anonimizados** — cadastro anonimizado de dependentes vinculados aos empregados.
- **workspace.bronze.empregados_anonimizados** — base anonimizada de empregados e vínculos, preservada em granularidade próxima da origem.
- **workspace.bronze.faturamento_anonimizado** — registros anonimizados de faturamento e notas fiscais.
- **workspace.bronze.ferias_anonimizado** — registros históricos anonimizados de direitos e períodos de férias.
- **workspace.bronze.fornecedor_anonimizado** — amostra anonimizada de fornecedores e valores observados.
- **workspace.bronze.pj_anonimizado** — cadastro anonimizado de prestadores de serviço pessoa jurídica.
- **workspace.bronze.plano_saude_ate_2022** — tabela auxiliar com valores históricos de plano de saúde até 2022.
- **workspace.bronze.plano_saude_vital_de_2022_em_diante** — tabela auxiliar com valores de plano de saúde a partir de 2022.
- **workspace.bronze.salario_anonimizado** — histórico anonimizado de salários.
- **workspace.bronze.valor_ticket_2010_2025** — tabela auxiliar com valores históricos de ticket utilizados na reconstrução dos custos de TR e TA.

Os notebooks de carga agrupam fontes relacionadas; por isso, não existe uma relação de um notebook para cada tabela física. As tabelas de Empregados e as três tabelas auxiliares também integram a Bronze e são explicitadas acima para que a documentação da camada corresponda integralmente às 12 tabelas registradas no Unity Catalog.

12.3 Camada Silver

Os notebooks Silver aplicam seleção de atributos, tipagem, padronização, tratamento de nulos, deduplicação quando aplicável e demais regras de qualidade necessárias para preparar os dados para a modelagem analítica.

- **01_Silver_Empregado_Anonimizado** — trata e constrói a Silver de Empregados, consolidando os atributos utilizados para representar os vínculos empregatícios.
- **02_Silver_Salario_Beneficio_Anonimizado** — trata as estruturas Silver de Salários e Benefícios.
- **03_Silver_dependentes_anonimizado** — trata e padroniza os registros de Dependentes.
- **04_Silver_Ferias_anonimizado** — trata os direitos e períodos de férias e prepara a fonte para a modelagem Gold.
- **05_Silver_faturamento_anonimizado** — trata o Faturamento, preservando as informações necessárias à consolidação posterior por nota fiscal.
- **06_Silver_PJ_Fornecedor_anonimizado** — trata e padroniza as fontes de PJ e Fornecedores, respeitando a natureza cadastral de PJ e o caráter amostral de Fornecedores.
- **07_Silver_Alocacao_Anonimizado** — trata a fonte de Alocação e preserva o recorte efetivamente disponível, sem extrapolação histórica.

12.4 Camada Gold

Os notebooks Gold materializam o modelo dimensional utilizado nas análises. Eles constroem as dimensões e fatos a partir das estruturas tratadas na Silver e das tabelas auxiliares necessárias.

- **01_Gold_Dim_Entidade** — constrói a dimensão unificada de clientes e fornecedores.
- **02_Gold_Dim_Empregado** — constrói a dimensão de empregados no grão de vínculo, identificado pelo DRT.
- **03_Gold_Dim_Alocacao** — constrói a dimensão de alocação a partir do recorte disponível, sem forçar integração histórica com custos ou faturamento.
- **04_Gold_Dim_Tempo** — constrói a dimensão calendário utilizada nas relações temporais do modelo.
- **05_Gold_Dim_Saude** — constrói as referências utilizadas na reconstrução dos custos históricos de plano de saúde.

- **06_Gold_Fato_Custo_Pessoal** — constrói a fato anual de custo de pessoal por DRT, integrando salário, benefícios, férias, décimo terceiro, FGTS, encargos e demais componentes modelados.
- **07_Gold_Fato_Dependentes** — constrói a fato anual de dependentes e dos custos de saúde associados aos vínculos.
- **08_Gold_Fato_Ferias** — constrói a fato de direitos e períodos de gozo de férias por vínculo e período aquisitivo.
- **09_Gold_Fato_Faturamento** — constrói a fato de faturamento consolidada em uma linha por nota fiscal real.
- **10_Gold_Fato_fornecedor** — constrói a fato de fornecedores por fornecedor e competência observada.

12.5 Análises de Negócio

Os notebooks de análise utilizam as estruturas Silver e Gold para responder às perguntas de negócio mantidas no escopo final. As questões não executadas permanecem documentadas nas seções de evolução do escopo e limitações.

- **MVP_Questoes_Negocio_RH** — executa e documenta as 13 questões do módulo de Recursos Humanos.
- **MVP_Questoes_Negocio_Financeiro** — executa e documenta as 3 questões mantidas no módulo Financeiro.
- **MVP_Questoes_Negocio_Faturamento** — executa e documenta as 8 questões mantidas no módulo de Faturamento e Clientes.

12.6 Repositório público e código

Todo o código que compõe o MVP foi organizado em notebooks correspondentes às etapas descritas nesta seção e será disponibilizado no repositório público do GitHub utilizado para a entrega. Os dados empresariais não serão publicados. Na versão submetida, o endereço do repositório deve acompanhar este documento, permitindo consultar os notebooks de preparação, carga, transformação, modelagem e análise aqui relacionados.

13. Unity Catalog

O Unity Catalog é utilizado como camada de catalogação, governança e rastreabilidade dos objetos persistidos no Databricks. No MVP, os objetos estão organizados no catálogo ``workspace`` e nos schemas ``bronze``, ``silver`` e ``gold``, refletindo fisicamente a arquitetura Medalhão adotada no pipeline. Esta seção apresenta evidências da implementação no ambiente; a descrição detalhada dos campos ficará concentrada no Dicionário de Dados, evitando duplicação com o catálogo.

13.1 Organização das camadas

A estrutura observada no Catalog Explorer contém 12 tabelas na Bronze, 9 tabelas na Silver e 10 tabelas na Gold. As três capturas abaixo registram a organização física das camadas no catálogo ``workspace``.




Figura 8 — Canada Bronze no Unity Catalog.




Figura 9 — Canada Silver no Unity Catalog.




Figura 10 — Camada Gold no Unity Catalog.

13.2 Camada Bronze

A Bronze preserva os dados anonimizados carregados a partir das planilhas e controles de origem. Ela constitui o ponto inicial persistido do pipeline; os dados pessoais e empresariais sensíveis já chegam anonimizados ao ambiente do MVP. As 12 tabelas observadas no Unity Catalog são: `alocacao_anonimizado`, `beneficio_anonimizado`, `dependentes_anonimizados`, `empregados_anonimizados`, `faturamento_anonimizado`, `ferias_anonimizado`, `fornecedor_anonimizado`, `pj_anonimizado`, `plano_saude_ate_2022`, `plano_saude_vital_de_2022_em_diante`, `salario_anonimizado` e `valor_ticket_2010_2025`.

A descrição detalhada de colunas, tipos, significados e domínios está concentrada no Dicionário de Dados, evitando duplicação no README. Os notebooks documentam as transformações responsáveis pela passagem entre as camadas.

- `workspace.bronze.alocacao_anonimizado` — recorte anonimizado de alocação principal, utilizado como origem da Silver de Alocação.
- `workspace.bronze.beneficio_anonimizado` — benefícios do titular disponíveis na fonte de origem.
- `workspace.bronze.dependentes_anonimizados` — cadastro anonimizado de dependentes vinculados aos empregados.
- `workspace.bronze.empregados_anonimizados` — base anonimizada de empregados e vínculos, preservada em granularidade próxima da origem.
- `workspace.bronze.faturamento_anonimizado` — registros anonimizados de faturamento e notas fiscais antes dos tratamentos analíticos.
- `workspace.bronze.ferias_anonimizado` — registros históricos anonimizados de direitos e períodos de férias.
- `workspace.bronze.fornecedor_anonimizado` — amostra anonimizada de fornecedores e valores observados.
- `workspace.bronze.pj_anonimizado` — cadastro anonimizado de prestadores PJ, sem medidas financeiras suficientes para fato própria.
- `workspace.bronze.salario_anonimizado` — histórico anonimizado de salários utilizado na construção dos custos de pessoal.
- `workspace.bronze.plano_saude_ate_2022` — tabela auxiliar de valores de plano de saúde até 2022.
- `workspace.bronze.plano_saude_vital_de_2022_em_diante` — tabela auxiliar de valores de plano de saúde a partir de 2022.
- `workspace.bronze.valor_ticket_2010_2025` — tabela auxiliar de valores históricos de ticket utilizada na reconstrução de custos de benefícios.

13.3 Camada Silver

A Silver contém as estruturas refinadas utilizadas pelo modelo analítico. Nessa camada são aplicadas seleção de atributos, tipagem, padronização, tratamento de nulos, deduplicação quando aplicável e regras de qualidade documentadas nos notebooks. As 9 tabelas observadas são: `alocacao_anonimizado`, `beneficio_anonimizado`, `dependentes_anonimizados`, `empregados_anonimizados`, `faturamento_anonimizado`, `ferias_anonimizado`, `fornecedor_anonimizado`, `pj_anonimizado` e `salario_anonimizado`.

- `workspace.silver.empregados_anonimizados` — vínculos tratados e padronizados, com datas, situação e motivo de desligamento consistentes.
- `workspace.silver.salario_anonimizado` — histórico salarial tipado e preparado para cálculos de custo.
- `workspace.silver.beneficio_anonimizado` — benefícios do titular tratados para integração com os cálculos de pessoal.
- `workspace.silver.dependentes_anonimizados` — dependentes tratados e deduplicados por vínculo e nome.
- `workspace.silver.ferias_anonimizado` — direitos e períodos de férias tratados e preparados para modelagem Gold.
- `workspace.silver.faturamento_anonimizado` — faturamento tratado, preservando a possibilidade de múltiplas NFs por CR/competência.
- `workspace.silver.fornecedor_anonimizado` — amostra de fornecedores tratada e padronizada para análise por competência.
- `workspace.silver.pj_anonimizado` — cadastro PJ tratado, mantido como estrutura cadastral.
- `workspace.silver.alocacao_anonimizado` — recorte tratado de alocação, preservado sem extrapolação histórica.

13.4 Camada Gold

A Gold materializa o modelo dimensional orientado às questões de negócio. O Unity Catalog registra 10 tabelas: cinco dimensões — `dim_alocacao`, `dim_empregado`, `dim_entidade`, `dim_saude` e `dim_tempo` — e cinco fatos — `fato_custo_pessoal`, `fato_dependentes`, `fato_faturamento`, `fato_ferias` e `fato_fornecedor`. A estrutura detalhada, granularidade e significado dos atributos serão documentados no Dicionário de Dados e nos Modelos Conceitual e Lógico; os notebooks Gold permanecem como referência das regras de transformação.

- `workspace.gold.dim_entidade` — dimensão unificada de clientes e fornecedores.
- `workspace.gold.dim_empregado` — dimensão de vínculos empregatícios identificados por DRT.
- `workspace.gold.dim_alocacao` — dimensão das alocações/atividades observadas no recorte disponível.
- `workspace.gold.dim_tempo` — calendário contínuo utilizado nas relações temporais.
- `workspace.gold.dim_saude` — referências utilizadas na reconstrução dos custos de plano de saúde.
- `workspace.gold.fato_custo_pessoal` — custos anuais de pessoal por DRT.
- `workspace.gold.fato_dependentes` — dependentes e custos anuais de saúde por vínculo.
- `workspace.gold.fato_ferias` — direitos e períodos de gozo de férias por vínculo.
- `workspace.gold.fato_faturamento` — faturamento consolidado em uma linha por NF real.
- `workspace.gold.fato_fornecedor` — valores observados por fornecedor e competência.

13.5 Rastreabilidade (Lineage)

O Unity Catalog registra dependências entre tabelas e ativos consumidores. Para evitar repetição, o README utilizará dois exemplos representativos de lineage: Faturamento e Empregados/RH. Esses grafos constituem evidência da rastreabilidade efetivamente capturada pelo Databricks e não substituem o Modelo Lógico nem a documentação completa do pipeline.

Lineage for workspace.silver.empregados_anonimizados




Figura 12 — Lineage de empregados: Bronze → Silver → estruturas analíticas Gold/consumidores.

No caso de empregados, o lineage mostra `workspace.bronze.empregados\_anonimizados` alimentando `workspace.silver.empregados\_anonimizados`, com posterior utilização em estruturas analíticas, entre elas `dim\_empregado`, `fato\_custo\_pessoal` e `fato\_dependentes`, conforme registrado pelo Unity Catalog. A Bronze possui 155 colunas e a Silver 15, ilustrando o refinamento estrutural realizado antes do consumo analítico.

13.6 Integração com Dicionário de Dados, modelos e notebooks

Para evitar redundância documental, esta seção do Unity Catalog comprova a implementação física, a organização das camadas e a rastreabilidade. O Dicionário de Dados concentra nomes de campos, tipos, descrições e domínios; os Modelos Conceitual e Lógico documentam entidades e relacionamentos; e os notebooks registram as transformações executadas. Os links para esses artefatos serão associados ao repositório final do projeto.

14. Autoavaliação

O MVP permitiu aplicar, de forma integrada, conceitos de arquitetura Medalhão, modelagem dimensional, qualidade de dados, SQL, Python, Databricks e análise de negócio. O desenvolvimento evidenciou também a importância de reconhecer limites das fontes e de distinguir dado observado, premissa de modelagem e cálculo derivado. Em vez de preencher lacunas com inferências, o projeto optou por documentar as restrições e retirar do escopo análises que não poderiam ser sustentadas de forma consistente.

14.1 Atingimento dos objetivos

O objetivo central de construir um pipeline de dados em nuvem, organizado em arquitetura Medalhão e capaz de integrar diferentes domínios empresariais para consumo analítico, foi atingido. As camadas Bronze, Silver e Gold foram construídas e persistidas no Databricks, com tratamento de qualidade, modelagem dimensional, catálogo, rastreabilidade e análises de negócio. As perguntas de Recursos Humanos foram executadas, assim como as análises financeiras mantidas no escopo e oito das dez perguntas de Faturamento e Clientes.

O escopo original não foi integralmente respondido. As 13 perguntas de Alocações e Rentabilidade e a pergunta de faturamento por alocação permaneceram sem resposta porque a fonte de Alocação não possui histórico completo de movimentações nem apontamento de horas capaz de sustentar a associação temporal entre empregado, custo e receita. A previsão de faturamento também não foi executada, pois a série disponível não contém variáveis explicativas suficientes para uma projeção considerada defensável. Essas perguntas foram preservadas no documento, com as respectivas justificativas, em vez de serem removidas do objetivo original.

14.2 Experiência técnica e uso de Inteligência Artificial

Antes do início da Pós-Graduação, o autor não possuía experiência prática com Python ou SQL, tendo iniciado o aprendizado dessas linguagens durante o curso. Em razão dessa limitação técnica, o desenvolvimento dos códigos utilizados no projeto contou de maneira significativa com o apoio do ChatGPT, ferramenta de Inteligência Artificial generativa, principalmente na implementação e revisão de códigos Python e consultas SQL.

O uso da ferramenta ocorreu de forma iterativa. Regras de negócio, decisões de modelagem, premissas, perguntas analíticas e critérios de validação foram discutidos ao longo do desenvolvimento, enquanto os códigos eram executados no Databricks e seus resultados avaliados antes da continuidade das etapas seguintes. Quando os resultados apresentavam inconsistências ou não correspondiam às regras estabelecidas, códigos e premissas eram revistos.

Embora a implementação técnica tenha contado de maneira significativa com assistência de Inteligência Artificial, buscou-se manter a compreensão das transformações realizadas, a validação dos resultados obtidos e a rastreabilidade das decisões adotadas. O nível inicial de experiência com Python e SQL constitui uma limitação do processo de desenvolvimento e pode ter restringido a capacidade de desenvolver ou avaliar de forma independente soluções técnicas mais sofisticadas; ao mesmo tempo, a construção do MVP integrou o próprio processo de aprendizagem dessas tecnologias.

14.3 Principais dificuldades

As principais dificuldades estiveram na preparação e anonimização consistente de fontes relacionadas, na heterogeneidade de estruturas e períodos de cobertura, na definição de grãos adequados para as tabelas Gold e na necessidade de distinguir problemas de qualidade de limitações inerentes às fontes. A preservação das correspondências entre pessoas, clientes, fornecedores e Centros de Resultado exigiu sucessivos ciclos de validação. Também foi necessário evitar integrações aparentemente possíveis, mas sem sustentação temporal suficiente, especialmente no domínio de Alocação.

14.4 Trabalhos futuros

Como evolução do projeto, a principal oportunidade é incorporar histórico completo de movimentações de alocação e apontamentos de horas por empregado e projeto. Isso permitiria relacionar temporalmente custos de pessoal e faturamento, viabilizando as análises de rentabilidade originalmente propostas. Outras extensões possíveis incluem ampliar a cobertura histórica de fornecedores e benefícios, registrar datas de inclusão e exclusão de dependentes nos planos e incorporar variáveis contratuais, comerciais e macroeconômicas que permitam avaliar, em trabalho futuro, modelos de previsão de faturamento com fundamentação mais adequada.

15. Conclusão

O MVP resultou em uma arquitetura analítica integrada no Databricks, estruturada nas camadas Bronze, Silver e Gold e documentada por meio do Unity Catalog, Dicionário de Dados, modelos e notebooks. A solução consolidou dados de diferentes domínios e permitiu responder às questões de negócio suportadas pelas fontes, com análises finais de Recursos Humanos, Financeiro e Faturamento.

As limitações encontradas foram tratadas como parte do resultado do trabalho. O módulo de Alocações e Rentabilidade, o faturamento por alocação e a previsão de faturamento não foram artificialmente produzidos quando os dados não ofereciam sustentação suficiente. Da mesma forma, as simplificações adotadas para viabilizar determinados cálculos foram explicitadas como premissas do modelo, sem apresentá-las como reprodução integral da realidade operacional.

O projeto demonstra, assim, não apenas a construção de um pipeline e de um modelo dimensional, mas também um processo de integração, validação e análise orientado à rastreabilidade e à transparência sobre aquilo que os dados permitem — e aquilo que não permitem — concluir.

16. Dicionário de Dados e Modelos Conceitual e Lógico

Esta seção consolida o dicionário de dados e os modelos conceitual e lógico utilizados como documentação de referência do MVP. O dicionário registra entidades, atributos, tipos, domínios, obrigatoriedade, regras de negócio e observações de validação. Os modelos conceitual e lógico representam a estrutura relacional de referência elaborada a partir das fontes; a implementação analítica final em arquitetura dimensional permanece documentada na seção 7 e no Unity Catalog.

16.1 Dicionário de Dados — Entidades

#	Nome do atributo / entidade	Tipo	Domínio de valores válidos	Obrigatório	Regra de negócio	Validação / observação
1	EMPREGADO - Funcionário da empresa					
	Nome	Mono simples	Texto até 100 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	
	Id Matricula	Mono simples Identificador	Número inteiro 4 dígitos	Sim	Identificador único do empregado gerado automaticamente	
	Endereço	Mono composto	-	Sim	Atributo agrupador	
	CEP	Mono simples	Número inteiro 8 dígitos	Sim	Validar junto à base oficial dos Correios	
	Logradouro	Mono simples	Texto até 100 caracteres	Sim	Preenchimento obtido automaticamente via CEP	
	Bairro	Mono simples	Texto até 100 caracteres	Sim	Preenchimento obtido automaticamente via CEP	
	Cidade	Mono simples	Texto até 100 caracteres	Sim	Preenchimento obtido automaticamente via CEP	
	Estado	Mono simples	Sigla com 2 caracteres	Sim	Obter via CEP. Deve corresponder a uma UF válida do Brasil	
	Número	Mono simples	Texto até 15 caracteres	Sim	Número predial ou 'S/N'	
	Complemento	Mono simples	Texto até 25 caracteres	Não	Informação opcional de bloco, vila ou ponto de referência	
	Sexo	Mono simples	Texto 1 caracter	Sim	Selecionar (M, F ou X)	
	Data Nascimento	Mono simples	Data	Sim	Idade mínima: (Data corrente - Data Nascimento)/365 >= 18 anos	
	Data Admissão	Mono simples	Data	Sim		
	Estado Civil	Mono simples	Texto até 15 caracteres	Sim		
	CPF	Mono simples	Texto 11 caracteres	Sim	Usado para quando houver a contratação de um ex-funcionário.	
	Unidade	Mono simples	Texto 4 caracteres	Sim	Usado para alternar informações quando houver mais de uma sede.	
2	DESLIGAMENTO - Ex Funcionário da empresa (Entidade Fraca)					
	Data Desligamento	Mono simples	Data	Sim		
	Motivo Desligamento	Mono simples	Texto até 30 caracteres	Sim	Selecionar uma das opções: Problema comportamental, falta de alocação, motivação salarial, Falta de conhecimento tecnico ou ter pedido demissão.	Funcionário pode sair da empresa por vontade própria ou ser demitido. Aqui busca-se registrar o que aconteceu, para poder criar políticas para melhorar o nível de serviço.
	Id_Desligamento	Mono simples Identificador	Número inteiro 6 dígitos	Sim	Identificador único do empregado gerado automaticamente	É o mesmo Id do empregado, seguido do dois dígitos do ano em que foi desligado.
3	DEPENDENTES - Relação dos Dependentes de Funcionários da empresa (Entidade Fraca)					
	Id Dependente	Mono simples Identificador	Número inteiro 5 dígitos	Sim	Identificador único do dependente gerado automaticamente	Identificador do dependente composto pela matrícula do empregado responsável e por um número sequencial do dependente.
	Nome Dependente	Mono simples	Texto até 100 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	
	Data Nascimento	Mono simples	Data	Sim		Importante para saber o custo do plano de saúde que varia por faixa etária.
	Sexo	Mono simples	Texto 1 caracter	Não	Selecionar (M, F ou X)	
4	HISTORICO DE FERIAS - Registro de Férias Gozadas dos Funcionário da empresa (Entidade Fraca)					

#	Nome do atributo / entidade	Tipo	Domínio de valores válidos	Obrigatório	Regra de negócio	Validação / observação
	Data Início	Mono simples Identificador	Data	Sim		Data de início do período de férias. Data Início + Período Aquisitivo formam conjuntamente o discriminador de HISTÓRICO DE FÉRIAS
	Data Fim	Mono simples	Data	Sim	Data Fim > Data Início	Data de termino desse período de férias
	Período Aquisitivo	Mono simples Identificador	Texto até 25 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	Período ao qual o funcionario teve direito a um determinado período de férias.
5	FERIAS - Registro de Férias a serem Gozadas dos Funcionário da empresa (Entidade Fraca)					
	Id Férias	Mono simples Identificador	Número inteiro 6 dígitos	Sim	Identificador único da ocorrência de férias gerado automaticamente	É composto do Id empregado responsável seguido pelo dois últimos dígitos do ano do período aquisitivo.
	Abono Pecuniario	Mono simples	Texto até 3 caracteres	Sim	Selecionar (Sim ou Não)	Significa que funcionário vendeu 10 dias de férias.
	Data Aviso de Férias	Mono simples	Data	Sim		Data para comunicar o empregado quando ele pode sair de férias
	Data Início	Mono simples	Data	Sim		Data de início do período de férias
	Data Fim	Mono simples	Data	Sim	Data Fim > Data Início	Data de termino desse período de férias
6	SALARIOS - Registro de Salarios dos Funcionário da empresa (Entidade Fraca)					
	Salario	Mono simples	Número real 5 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Cargo	Mono simples	Texto até 25 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	Há alteração salarial se um funcionário mudar de cargo/ função.
	Data Alteração Salarial	Mono simples Identificador	Data	Sim		Data que houve alteração Salarial
	Descrição	Mono simples	Texto até 100 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	Descrição do motivo da alteração salarial
7	BENEFICIOS - Registro de Benefícios dos Funcionário da empresa (Entidade Fraca)					
	Id Benefícios	Mono simples Identificador	Número inteiro 5 dígitos	Sim	Identificador único do empregado gerado automaticamente	Identificador do benefício composto pela matrícula do empregado responsável e por um número sequencial do benefício.
	Beneficio	Mono composto	-	Sim	Atributo agrupador	Sempre que um ou mais beneficios sofrerem alteração, será gerado uma nova tupla com os valores que sofreram alteração e os demais que não sofreram serão copiados, de forma que a nova tupla indica a data da ultima revisão de todos os beneficios.
	Vale Refeição	Mono simples	Número real 3 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Plano de Saúde	Mono simples	Número real 4 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Plano Dental	Mono simples	Número real 2 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Data Alteração Beneficio	Mono simples	Data	Sim		Quando qualquer beneficio for alterado, registra-se uma nova situação completa do conjunto de beneficios vigentes nessa data.
8	FATURAMENTO - Registro de notas fiscais emitidas (entrada de caixa) pela empresa (Entidade Fraca)					
	Id Faturamento	Mono simples Identificador	Texto 8 dígitos	Sim	Identificador único do faturamento gerado automaticamente	É composto pelo número da nota fiscal (NF), que

#	Nome do atributo / entidade	Tipo	Domínio de valores válidos	Obrigatório	Regra de negócio	Validação / observação
						distingue as ocorrências de faturamento dentro de uma mesma competência.
	Valor da Nota Fiscal Cliente	Mono simples	Número real 7 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Nome Cliente	Mono simples	Texto até 50 caracteres	Sim		Considera-se que possa haver uma ou mais emissões de NF na mesma competência, para uma mesma alocação de um cliente.
	Data Vencimento Nota Fiscal Cliente	Mono simples	Data	Sim		
9	Alocação - Registro das Alocações da empresa					
	Centro Resultado Alocação	Mono composto identificador	-	Sim	Atributo agrupador	Lei de formação é coposto por 4 partes: a 1ª é o Id do núcleo (ex: Nex0), 2ª é o Id do cliente (é formado por 3 letras), 3ª é o Id da alocação (é formado por três letras) e por último sequencial formado por 3 números ou letras (se um projeto tiver continuação). Ex: NX0.IBS.YLJ.001
	Id Departamento	Mono simples	Texto de 4 caracteres	Sim	Selecionar entre: Nex0, Nex1, Nex2, Nex3 e Nexa	Os departamentos que podem cuidar de alocação são os Nex0 até Nex3. Departamento que cuida de desalocação é o Nexa.
	Id Cliente	Mono simples	Texto de 3 caracteres	Sim	Identificador gerado pelo gerente	É composto por três letras
	Id Alocação	Mono simples	Texto até 3 caracteres	Sim	Identificador gerado pelo gerente	
	Id Sequencial	Mono simples	Texto de 3 caracteres	Sim	Identificador gerado pelo gerente	É composto por três letras ou números
	Nome Alocação	Mono simples	Texto até 100 caracteres	Sim	Campo de texto sem caracteres especiais e monetários	Nome da alocação.
	Tipo de Perfil Profissional	Mono simples	Texto até 3 caracteres	Sim	Selecionar (ADM ou TEC)	Filtro para saber se profissional é administrativo (ADM) ou técnico (TEC)
10	PLANO DE SAÚDE - Registro das características do Plano de Saúde					
	Id Plano Saúde	Mono simples Identificador	Texto de 3 caracteres	Sim		São dois tipos de plano: um gerencial e outro para a equipe
	Faixa Plano Saúde	Mono simples	Texto até 15 caracteres	Sim		São dez faixas etárias do plano de saúde. De 0 a 18 anos, 19 a 23 anos, 24 a 28 anos, etc.
	Custo Plano Saúde	Mono simples	Número real 4 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	Cada faixa possui um custo associado O custo é crescente e de acordo com o aumento de idade.
11	COBRANÇA - Registro de notas fiscais emitidas (saida de caixa) pelos Fornecedores da empresa					
	Valor da Nota Fiscal Fornecedor	Mono simples	Número real 7 dígitos	Sim	Valor monetário em Reais (R\$). Deve ser estritamente maior que zero (> 0).	
	Nome Fornecedor	Mono simples Identificador	Texto até 50 caracteres	Sim		Fornecedores só emitem uma única nota fiscal por mês.
	Data Vencimento Nota Fiscal Fornecedor	Mono simples Identificador	Data	Sim		
12	CLIENTE - Registro de Clientes da empresa					

16.2 Dicionário de Dados — Relacionamentos

#	Relacionamento	Entidades	Cardinalidades	Atributo	Tipo	Domínio	Obrigatório	Regra de negócio / ajuste
1	RELACIONAMENTO: Empregado e Alocação							
	Aloca	Empregado	(0,N)	Data Início Alocação	Data		Sim	Um empregado pode não possuir nenhuma alocação ou pode participar de diversas alocações ao longo do tempo.
		Alocação	(1,N)	Data Fim Alocação	Data	Data Fim Alocação > Data Início Alocação	Não	Uma alocação deve possuir pelo menos um empregado e pode possuir diversos empregados.
				Função Profissional	Mono simples	Texto até 50 caracteres	Sim	Cargo (Ex Gerente de Projetos, Analista de Sistema Sênior, etc).
				Desalocação	Mono simples	Texto até 3 caracteres	Sim	Flag para identificar se um profissional está alocado ou desalocado.
				Id Aloca	Mono simplesIdentificador	Texto até 9 caracteres	Sim	Identificador composto do código do cliente seguindo pelo da alocação e e por fim o sequencial
2	RELACIONAMENTO: Empregado e Dependente							
	Depende	Empregado	(0,N)				Sim	Um empregado pode ter mais de um dependente no plano de saúde.
		Dependente	(1,1)					Um dependente só pode ser dependente de um único empregado.
3	RELACIONAMENTO: Empregado e Salário							
	Recebe	Empregado	(1,N)				Sim	Todo empregado possui pelo menos um registro salarial, correspondente ao salário de admissão, podendo possuir diversos registros ao longo do tempo em decorrência de reajustes, promoções ou outras alterações salariais.
		Salário	(1,1)					Cada registro salarial representa a situação salarial de um único empregado em determinada data.
4	RELACIONAMENTO: Empregado e Férias							
	Descansa	Empregado	(0,3)				Sim	Um empregado pode não possuir férias em aberto ou possuir até três ocorrências de férias relativas ao fracionamento do período corrente, respeitando o limite total de dias definido para o período.
		Férias	(1,1)					Cada ocorrência de férias em aberto pertence a um único empregado.
5	RELACIONAMENTO: Empregado e Benefício							
	Beneficia	Empregado	(1,N)				Sim	Todo empregado possui pelo menos um registro completo de seus benefícios e pode possuir

#	Relacionamento	Entidades	Cardinalidades	Atributo	Tipo	Domínio	Obrigatório	Regra de negócio / ajuste
								diversos registros ao longo do tempo sempre que ocorrer alteração em um ou mais benefícios.
		Benefício	(1,1)					Cada registro de benefícios representa a situação completa dos benefícios de um único empregado em determinada data.
6	RELACIONAMENTO: Plano Saúde e Benefício							
	Utiliza	Plano Saúde	(0,N)				Sim	Uma ocorrência de plano de saúde pode não estar associada a nenhum registro de benefício ou pode ser utilizada por diversos registros de benefício.
		Benefício	(1,1)					Cada registro de benefício utiliza exatamente uma ocorrência de plano de saúde.
7	RELACIONAMENTO: Alocação e Faturamento							
	Gera	Alocação	(1,N)				Sim	Uma alocação gera um ou mais faturamentos ao longo do tempo, podendo existir mais de um faturamento associado à mesma alocação em uma mesma competência.
		Faturamento	(1,1)					Um faturamento é gerado para uma alocação.
8	RELACIONAMENTO: Empregado e Histórico Férias							
	Registra	Empregado	(0,N)				Sim	Um empregado pode não possuir histórico de férias ou pode possuir diversos registros de férias concluídas ao longo do tempo.
		Histórico Férias	(1,1)					Cada registro de histórico de férias pertence a um único empregado.
9	RELACIONAMENTO: Alocação e Cobrança							
	Rateia	Alocação	(1,N)	percentual de rateio	Número real percentual	0 < percentual de rateio <= 100%	Sim	Uma alocação recebe o rateio de uma ou mais cobranças ao longo do tempo. A soma dos percentuais de rateio de uma mesma cobrança deve ser igual a 100%.
		Cobrança	(1,N)					Uma cobrança é rateada entre uma ou mais alocações ativas.
				Id Rateia	Mono simplesIdentificador			
10	RELACIONAMENTO: Empregado e Desligamento							
	Desliga	Empregado	(0,1)				Sim	Um empregado pode ser desligado da empresa.
		Desligamento	(1,1)					Um desligamento representa a saída de um empregado.
11	RELACIONAMENTO: Alocação e Cliente							
	Atende	Alocação	(1,1)				Sim	Uma alocação atende um único

#	Relacionamento	Entidades	Cardinalidades	Atributo	Tipo	Domínio	Obrigatório	Regra de negócio / ajuste
		Cliente	(0,N)					Um cliente pode ser atendido por nenhuma ou diversas alocações.

16.3 Modelo Conceitual

O modelo conceitual apresenta as principais entidades do domínio e seus relacionamentos, independentemente da implementação física utilizada nas camadas analíticas.




Figura 13 — Modelo Conceitual de Dados.

16.4 Modelo Lógico

O modelo lógico detalha atributos, chaves e cardinalidades da estrutura relacional de referência. O modelo dimensional efetivamente implementado na Gold é documentado separadamente no catálogo da camada Gold.




Figura 14 — Modelo Lógico de Dados.